

## Parte X

# Teste de geradores de números aleatórios

- Os usuários de uma simulação devem se certificar de que os números fornecidos pelo gerador de números aleatórios são suficientemente aleatórios.
- O primeiro passo é plotar o histograma e as distribuições acumuladas.
  - Este é um teste rápido que permite identificar erros grosseiros de implementação.
  - Para construir um histograma, particionamos a região de valores possíveis em  $k$  intervalos consecutivos. Em seguida verificamos a proporção de valores que ocorrem em cada intervalo, e verificamos se esta proporção se aproxima da esperada pela distribuição subjacente.
- Em seguida, deve-se realizar todos os testes estatísticos possíveis.
  - Descreveremos cada um destes testes nas próximas seções.
  - Passar em cada teste é uma condição necessária, mas não suficiente. Ou seja, se o teste falha podemos assumir que o gerador é ruim. Porém, passar no teste não é uma garantia que ele é bom, pois ele pode falhar
    - \* no teste seguinte,
    - \* ou no mesmo teste quando utilizamos outra semente ou outra parte do ciclo.
- Com o surgimento de novos testes, geradores que eram considerados bons deixaram de ser.
- Embora os testes apresentados aqui são para distribuições uniformes, muitos destes testes podem ser adaptados para outras distribuições.
  - A aleatoriedade dos geradores de números distribuídos uniformemente é mais importante, pois estes números são utilizados para produzir geradores de números que respeitam outras distribuições.
- Os testes podem ser classificados como empíricos e teóricos.
  - Os testes empíricos consideram o gerador como uma caixa preta. Os números que saem do gerador são avaliados com técnicas estatísticas.
  - Por outro lado, os testes teóricos avaliam propriedades matemáticas desejáveis nos geradores. Para isso, estes métodos levam em conta a forma como cada gerador produz os números.

- Os testes teóricos são sofisticados e envolvem ferramentas matemáticas mais complexas.
  - Eles indicam a qualidade de um gerador (de acordo com algum critério matemático) sem exigir a geração de números, mas avaliando sua definição. Ex.: nos geradores congruente lineares, eles avaliam as constantes  $a$ ,  $c$  e  $m$ .
  - Estes testes também diferem dos empíricos por avaliar todo o ciclo do gerador, e não apenas um segmento dos números gerados.
  - Com excessão do teste espectral, todos os testes apresentados aqui são empíricos.

## 38 Testes de Ajuste à Distribuição

### 38.1 Teste Chi-Quadrado

- Este é o teste mais utilizado para determinar se os dados observados atendem a uma determinada distribuição.
- Os passos são:
  1. Preparamos um histograma com  $k$  intervalos, obtendo assim o percentual de ocorrência  $o_i$  em cada intervalo  $i = 1, \dots, k$ .
  2. Com base na distribuição que estamos testando, determinamos o percentual de ocorrências esperado  $e_i$  para cada intervalo  $i = 1, \dots, k$ .
    - No caso da distribuição uniforme,  $e_i = 1/k$  para todo  $i$ .
  3. Calculamos a estatística
$$D = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i},$$
que tem distribuição chi-quadrada com  $k - 1$  graus de liberdade.
  4. Com significância  $\alpha$ , se  $D$  é menor que  $\chi_{1-\alpha, k-1}^2$  (fornecido em softwares ou tabelas), não podemos rejeitar a hipótese de que os números foram originados da distribuição.
- Ex.: determinar (com significância  $\alpha = 0.10$ ) se o gerador  $x_n = (125x_{n-1} + 1) \bmod 2^{12}$ ,  $x_0 = 1$ , fornece números de acordo com uma distribuição uniforme entre 0 e 1.
  - 1000 números foram gerados, e um histograma com 10 intervalo foi criado (Tabela 27.1, Jain). Esperamos 100 observações em cada intervalo (10%).
  - Resultou em  $D = 10.38$ . Como  $\chi_{0.9, 9}^2 = 14.68$ , não podemos rejeitar a hipótese de que os números gerados são uniformes.

```
n=1000; m=2^12; a=125; b=1; x=zeros(1,n);
x(1)=1;
for i=2:n; x(i)=mod(a*x(i-1)+b,m); end;
x=x/m; hist(x); grid on; figure; autocorr(x)
```

```
[h pv]=chi2gof(x,'cdf',@(z)unifcdf(z),
'npars',0,'alpha',0.05)
```

- Como o  $e_i$  aparece no denominador, erros em intervalos com  $e_i$  menores têm mais peso na estatística  $D$ .

- Portanto, o teste funciona melhor se os intervalos do histograma são escolhidos de tal forma que os  $e_i$ 's sejam iguais.
- Uma forma aproximada de resolver é agrupar cada intervalo com  $e_i$  pequeno com algum intervalo vizinho.
- Note que no caso da distribuição uniforme, basta utilizar um histograma com intervalos de mesmo tamanho.

- Se  $r$  parâmetros da distribuição são estimados utilizando a mesma amostra, o número de graus de liberdades cai de  $k - 1$  para  $k - 1 - r$ .

- Ex.: se suspeitamos que os dados formam uma normal, e estimamos a média e o desvio padrão com base na amostra, devemos subtrair 2 graus de liberdade.
- No caso da distribuição uniforme entre 0 e 1 nenhum parâmetro precisa ser estimado.

- Este teste é mais indicado para distribuições discretas.

- No caso de distribuições contínuas, o teste chi-quadrado é apenas uma aproximação. E portanto exige mais observações.
- Pois o teste agrupa (discretiza) os dados em intervalos, unindo valores com probabilidades diferentes (isto pode ser evitado em distribuições discretas).
- Assim, o nível de significância real apenas se aplica para um número infinito de observações (intervalos).
- Na prática (amostras finitas), reduzimos este efeito evitando a ocorrência de intervalos com poucas observações: cada intervalo com menos de 5 observações é agrupado com algum intervalo vizinho.

\* Quando o intervalo tem mais observações temos mais confiança da proporção observada.

## 38.2 Teste Kolmogorov-Smirnov

- Passos:

1. Determine a função de distribuição acumulada observada  $F_o(x)$ , e a função de distribuição acumulada esperada  $F_e(x)$ .
2. Utilizando os  $n$  valores da amostra, calcule as estatísticas

$$K^+ = \sqrt{n} \times \max_x \{F_o(x) - F_e(x)\}$$

$$K^- = \sqrt{n} \times \max_x \{F_e(x) - F_o(x)\},$$

que representam as maiores diferenças entre as distribuições para mais e para menos.

3. Com significância  $\alpha$ , não podemos rejeitar a hipótese de que os dados obedecem a distribuição se  $K^+$  e  $K^-$  forem menores que  $K_{1-\alpha,n}$  (obtido em tabela).
- A função de distribuição acumulada observada  $F_o(x)$  é o percentual de observações com valor menor ou igual a  $x$ , ou seja:

- Sejam  $x_1 \leq x_2 \leq \dots \leq x_n$  os elementos da amostra em ordem crescente. Então,

$$F_o(x) = \begin{cases} 0, & \text{se } x < x_1 \\ i/n, & \text{se } x_i \leq x < x_{i+1}, \quad i = 1, \dots, n-1 \\ 1, & \text{se } x \geq x_n \end{cases}$$

- Existe uma observação importante no cálculo de  $K^-$  (figura 27.1, Jain).

- Toda função de distribuição acumulada é não decrescente.
- Como  $F_o(x)$  se baseia em um conjunto finito de observações, ela possui incrementos discretos (ou seja,  $F_o(x)$  é constante entre observações consecutivas  $x_i \leq x < x_{i+1}$ ).
- Por outro lado, quando a distribuição é contínua,  $F_e(x)$  será contínua.
- Assim, o  $\max_x \{F_e(x) - F_o(x)\}$  para  $x_{i-1} \leq x < x_i$  ocorre imediatamente antes de  $x_i$ . Ou seja,  $\max_{x_{i-1} \leq x < x_i} \{F_e(x) - F_o(x)\}$  converge para  $F_e(x_i) - F_o(x_{i-1})$ .

- Para a distribuição uniforme entre 0 e 1 temos que  $F_e(x) = x$ . Portanto,

$$K^+ = \sqrt{n} \times \max_{i=1, \dots, n} \left\{ \frac{i}{n} - x_i \right\}$$

$$K^- = \sqrt{n} \times \max_{i=1, \dots, n} \left\{ x_i - \frac{(i-1)}{n} \right\}$$

- Ex.: tabela 27.2, Jain.

- Comparando com o teste Chi-quadrado, concluímos:

- Ao contrário do teste Chi-quadrado, que é mais apropriado para distribuições discretas e amostras grandes, o teste K-S foi projetado para distribuições contínuas e amostras pequenas.
- O teste K-S compara as distribuições acumuladas (teórica e observada), enquanto o teste Chi-quadrado compara as densidades de probabilidades.
- Ao contrário do teste Chi-quadrado, o teste K-S não faz agrupamento de observações. Neste sentido, o teste K-S faz melhor uso dos dados.
- A escolha dos tamanhos dos intervalos é um problema do teste Chi-quadrado (não existe regras bem definidas para isso). Esta escolha afeta o resultado.
- O teste Chi-quadrado é sempre aproximado, enquanto o teste K-S é exato sempre que os parâmetros da distribuição são conhecidos.

```
n=1000; m=2^12; a=125; b=1; x=zeros(1,n);
x(1)=1;
for i=2:n; x(i)=mod(a*x(i-1)+b,m); end;
x=x/m; hist(x); grid on; figure; autocorr(x)
```

```
[h p]=kstest(x',[x' unifcdf(x')],0.05)
```

MIDSQUARE

```
n=100; x=zeros(1,n); x(1)=1234;
for i=2:n;
    x(i)=mod(floor(x(i-1)*x(i-1)/100),10000);
end;
x=x/10000; hist(x)
```

```
[h pv]=chi2gof(x,'cdf',@(z)unifcdf(z),
    'nparams',0, 'alpha',0.05)
[h p]=kstest(x',[x' unifcdf(x')],0.05)
```

### 38.3 Teste de correlação serial

- A covariância é um método direto de testar dependência entre duas variáveis aleatórias.
  - Se a covariância é não nula, existe dependência entre elas (linear).
  - Porém, se a covariância é nula, pode haver dependência não linear entre elas.
- Dada uma sequência  $X_1, \dots, X_n$  de variáveis aleatórias, podemos testar a covariância entre variáveis separados por  $k$  posições na sequência, ou seja, entre  $X_i$  e  $X_{i+k}$  para  $i = 1, \dots, n - k$ .
  - Esta medida é chamada de “autocovariância” de “lag”  $k$ , e é expressa por

$$R_k = \frac{1}{n-k} \sum_{i=1}^{n-k} (X_i - E[X_i]) (X_{i+k} - E[X_{i+k}]).$$

- Se  $X$  é uniforme entre 0 e 1, então  $E[X] = 1/2$ .

- Se  $n$  é grande, e as variáveis aleatórias são independentes com distribuição uniforme entre 0 e 1, então  $R_k$  (para  $k \geq 1$ ) tem distribuição normal com média zero e variância  $1/[144(n-k)]$ .

- A forma normal vem do “Teorema Central do Limite”.

- Quando duas variáveis  $X$  e  $Y$  são independentes (o que implica em correlação nula), temos  $E[XY] = E[X]E[Y]$  (pois a correlação é igual a  $E[XY] - E[X]E[Y]$ ). Portanto,  $E[R_k] = 0$  e  $E[R_k^2]$

$$= \frac{1}{(n-k)^2} \sum_{i=1}^{n-k} E \left[ \left( X_i - \frac{1}{2} \right)^2 \left( X_{i+k} - \frac{1}{2} \right)^2 \right]$$

$$= \frac{1}{144(n-k)},$$

pois os produtos cruzados são nulos, e se  $X$  é uniforme entre  $-1/2$  e  $1/2$ , então  $E[X^2] = \int_{-1/2}^{1/2} X^2 dx = 1/12$ .

- Portanto, para  $k \geq 1$  o intervalo de confiança  $100(1 - \alpha)\%$  para a autocovariância é

$$R_k \pm \frac{z_{1-\alpha/2}}{12\sqrt{n-k}},$$

onde  $z_\beta$  (obtido em tabela) é tal que  $\Pr[X \leq z_\beta] = \beta$  se  $X$  tem distribuição uniforme com média 0 e desvio padrão 1.

- Para cada valor de  $k \geq 1$  desejado, o teste consiste em determinar se o valor zero pertence ao intervalo de confiança da autocovariância de lag  $k$ .

- Se não pertencer, não podemos rejeitar a hipótese de que não existe autocovariância de lag  $k$ .

- Quando  $k = 0$ ,  $R_0$  é a variância da sequência, cujo valor esperado é  $1/12$  quando os valores são independentes e uniformes entre 0 e 1.

```
n=1000; m=2^12; a=125; b=1; x=zeros(1,n);
x(1)=1;
for i=2:n; x(i)=mod(a*x(i-1)+b,m); end;
x=x/m;

%x=(1:n)/n;
for k=1:10,
    r=sum((x(1:end-k)-.5).*(x(k+1:end)-.5))/(n-k);
    s=norminv(.975)/(12*sqrt(n-k)); [r-s, r+s]
end
```

## 39 Testes de Uniformidade $d$ -dimensional

- Uma observação feita por Marsaglia (1968) revelou a necessidade de se testar a uniformidade em dimensões maiores:

- “Números aleatórios ocorrem principalmente em planos.”
- Isto significa que as tuplas sobrepostas  $(x_1, x_2, \dots, x_d), (x_2, x_3, \dots, x_{d+1}), \dots$  ocorrem em um número pequeno de hiperplanos (espaços vetoriais com dimensão  $d-1$ ) no espaço vetorial de dimensão  $d$ , que cruzam o hipercubo  $[0, 1]^d$ .
- Isto também ocorre para tuplas não sobrepostas  $(x_1, x_2, \dots, x_d), (x_{d+1}, x_{d+2}, \dots, x_{2d}), \dots$
- Ex.: 2 dimensões: figura 7.2, Law. 3 dimensões: figura 7.4, Law.
- Dependendo do espaçamento entre hiperplanos, o resultado pode ser mais aceitável. Ex.: figura 7.1, Law.
- Além da inspeção visual, vamos considerar dois destes testes de uniformidade  $d$ -dimensional: o teste serial (empírico) e o teste espectral (teórico).

```
n=17; m=16; a=5; b=3; x=zeros(1,n); x(1)=7;
for i=2:n; x(i)=mod(a*x(i-1)+b,m); end;
x=x/m;
```

```
scatter(x(1:end-1), x(2:end))
%scatter3(x(1:end-2), x(2:end-1), x(3:end))
```

### 39.1 Teste Serial

- Passos:
  - Divida o espaço no hipercubo  $[0, 1]^d$  em  $K^d$  células de igual tamanho. Ex.: figura 27.5, Jain.
  - Utilizando uma amostra  $x_1, \dots, x_n$ , produza  $n/d$  tuplas não sobrepostas.
  - Conte quantas tuplas ocorrem em cada célula. Esperamos encontrar  $n/(dK^d)$  tuplas em cada célula.
  - Utilize o teste Chi-quadrado, com  $K^d - 1$  graus de liberdade. Note que este teste exige que as observações sejam independentes, portanto as tuplas não podem ser sobrepostas.

```
n=18; m=16; a=5; b=3; x=zeros(1,n); x(1)=7;
for i=2:n; x(i)=mod(a*x(i-1)+b,m); end;
x=x/m;
```

```
d=2; k=3;
v=1:length(x);
x1=x(v(mod(v,2)==0)); x2=x(v(mod(v,2)==1));
```

```
c = zeros(1,d*k);
for i=1:k,
    for j=1:k,
        c(k*(i-1)+j) = sum((x1 >= (i-1)/k) & (x1 < i/k) ...
            & (x2 >= (j-1)/k) & (x2 < j/k));
    end
end
```

```
[h p]=chi2gof(c,'nbins', d*k, 'expected', ...
    ones(1,d*k)*n/(d*k^d), 'alpha',0.05)
```

```
-----
n=1000; m=2^12; a=125; b=1; x=zeros(1,n);
x(1)=1;
for i=2:n; x(i)=mod(a*x(i-1)+b,m); end;
x=x/m;

scatter(x(1:end-1), x(2:end))
figure; scatter3(x(1:end-2), x(2:end-1), x(3:end))

d=2; k=3;
v=1:length(x);
x1=x(v(mod(v,2)==0)); x2=x(v(mod(v,2)==1));
c = zeros(1,d*k);
for i=1:k,
    for j=1:k,
        c(k*(i-1)+j) = sum((x1 >= (i-1)/k) & (x1 < i/k) ...
            & (x2 >= (j-1)/k) & (x2 < j/k));
    end
end
```

```
[h p]=chi2gof(c,'nbins', d*k, 'expected', ...
    ones(1,d*k)*n/(d*k^d), 'alpha',0.05)
```

### 39.2 Teste Espectral

- Este teste determina a máxima distância entre hiperplanos adjacentes. Quanto maior esta distância, pior o gerador.
- Quando o período é pequeno, esta distância pode ser determinada por enumeração.
- Ex.: 27.7, Jain: comparar os geradores  $x_n = 3x_{n-1} \bmod 31$  e  $x_n = 13x_{n-1} \bmod 31$ , ambos com  $x_0 = 15$ .
  - Como ambos produzem ciclos com os mesmos números (em ordem diferente), ambos apresentam o mesmo resultado no teste serial.
  - Porém, os pares sobrepostos mostram diferenças: figuras 27.6 e 27.7, Jain.
  - No primeiro gerador temos 3 retas com máxima distância:  $x_n = 3x_{n-1} + 31k, k = 0, 1, 2$ . No segundo temos:  $x_n = -5x_{n-1}/2 + 31k/2, k = 0, \dots, 5$ .
  - A distância entre duas retas paralelas  $y = ax + c_1$  e  $y = ax + c_2$  vale  $|c_2 - c_1|/\sqrt{1 + a^2}$ .

- Assim, obtemos que a distância é menor no segundo gerador. Na inspeção visual também escolheríamos o segundo gerador.
- Este método permite o uso de tuplas sobrepostas e não sobrepostas.
  - Portanto, as sobrepostas deveriam ser utilizadas, pois produzem mais pontos:  $n - 1$  contra  $n/d$  no caso sem sobreposição.
- Para  $m$  grande ou dimensões maiores, a enumeração dos hiperplanos é inviável.
  - Existem métodos para calcular as distâncias sem enumeração (ver Knuth 1981), mas devido à sua complexidade, não detalharemos aqui.

## 40 Conclusões (Law)

- Existe grande variedade de testes para números aleatórios, e existe muita controvérsia sobre quais testes são melhores, e se testes teóricos são mais definitivos que os empíricos.
  - Ex.: se a amostra utilizada em um teste empírico for muito pequena, o resultado pode corresponder apenas a um pequeno fragmento do ciclo. Por outro lado, um teste que leva em conta um ciclo inteiro pode não ser compatível com fragmentos deste mesmo ciclo.
    - \* Podemos ter segmentos não aleatórios em ciclos considerados aleatórios.
  - De fato, nenhuma quantidade de testes pode convencer alguém que certo gerador é o melhor em todos os casos.
- Portanto, a recomendação é que os testes sejam consistentes com o uso que será dado ao gerador.
  - Ex.: se os números serão utilizados aos pares, examinar o comportamento de pares (talvez com um teste serial) seja o mais apropriado.
- Assim, o projetista deve ser cauteloso na escolha e no teste do gerador se a simulação é cara, requer alta precisão, ou é um componente crítico de um estudo mais amplo.